

bdelf BELF / RELF：设计与实现说明

bdelf 模型文档

2026 年 8 月 31 日

摘要

本文档完整说明 bdelf 中两族半自回归连续语言模型 BELF 与 RELF 的动机、流几何、时间场、损失、CFG、训练接口与推理循环。二者实现上可共享模块代码，但须分别描述、分别训练，且不共享参数。共用 ELF 约定的 rectified flow ($t = 1$ 为干净端)、token 对齐 VAE、2L pack、去噪器 G 。流空间是入口输出维 $X = \text{latent_dim}$ (须与 artifact 一致)； $D = \text{n_embd}$ 只是 G 隐层。出口锁死为 $\hat{x}_0 \in X$ 再走 VAE-dec；主体训练损失只有 v-MSE，不含出口 CE。推理时 VAE-dec 读 token。**BELF** 在块内未知槽共享同一标量 t ，已知余数钉干净条件，块间将提交结果写入 KV cache。**RELF** 训练时逐档独立连续 t ，推理时在窗内用降序梯子逐步 pop S 个槽；当前窗已知余数钉干净条件。日程档 full 下每一族、每一档 latent_tune 均须完成主训与扩展 token 预算；日程档 mid 仅 Stage1 (10B 全局批 128, eval_step=1000)，无扩展。生成长度上限为 max_seq_len。工程路径见同目录上级 README.md。本文档不冻结 GPU 机时额度，亦不提供训练结论。

1 动机与定位

ELF [1] 表明：在冻结上下文嵌入上，以 $t = 1$ 为干净端做线性插值，并由 x-pred 转换为速度均方误差，可在连续状态空间上完成观测恢复。其生成分解为整句共享一个标量 t 、注意力全程双向，因而既无 KV cache，也不能按块提交或作可变长增量生成。Cola [2] 与 AURORA-LM [3] 采用另一分解：冻结或先训练可解码 latent，再以块因果 Flow Matching 作为 prior，由独立 decoder 读出 token。该分解已是半自回归，但块内仍共享同一时间；Cola 的时间轴与 ELF 相反 ($t = 0$ 为干净端)，其主要主张为压缩语义 latent。

因此给出两条可分别训练与评测的半自回归 ELF：BELF 在块内未知槽共享单一连续时间 (已知余数钉干净)，RELF 训练时逐档独立连续 t 、推理时在窗内使用位置相关的降序时间梯子 (已知余数同样钉干净)。本文档中 VAE 将因果编码器输出映射为近似各向同性、可叠加高斯噪声的 token 对齐 latent，且不缩短序列长度。下文先陈述两族共用部分，再单开时间调度章，然后分章给出 BELF 与 RELF。本文档不设定 GPU 机时上限 (5090 与 A100 均未冻结额度)。

2 相关工作

本节陈述近邻工作的机制及其与本规格的差异。不以 full-width latent 本身作为设计贡献。BELF 对照 AURORA、BD3-LM 与 Cola 的块因果分解；RELF 对照 Rolling Diffusion 的局部时间场，并采用 ELF 的流几何。两族分别陈述、分别训练。

全程一个 t 的观测恢复。 ELF 冻结 T5 嵌入，采用 rectified flow，并由 x-pred 转换为速度均方误差。全序列双向、整句一个标量 t 。CoDAR [4] 将 rounding 外包给独立自回归 decoder，但仍是全序列连续扩散。二者均无已提交前缀进入 KV cache。

冻 AE + 块因果连续 prior。 Cola 将 $p(x, z_0) = p_\theta(x | z_0) p_\psi(z_0)$ 分解，并以 2L pack 一次输入干净前缀与当前块噪声。AURORA 冻结 Query-AE，对 full-width 可解码 latent 做块因果 Flow Matching。与 BELF 最近的近邻是：冻结编码器、块因果注意力、独立 decoder。BELF 当前块内已知余数采用 Cola 的 clean 条件：钉干净、只去噪未知槽。差异在于自编码器构造、流匹配配方，以及 Cola 不具备窗内降序时间梯子。

离散块同步 t 。 BD3-LM [5] 块间自回归、块内吸收态 mask、一块一个 t_b 、同一网络出 logits。这是 BELF 在离散观察空间上的对应物。本规格的状态是连续 VAE 码，token 由独立出口读出。

视频里的局部时间滑窗。 Rolling Diffusion [6] 将全局 t 映射为帧局部 t_k 。RELF 的局部时间场在滑窗后保持时间半群一致性，其约束源于该工作。其对象为视频或物理场，而非语言模型，亦无 KV cache 与 token decoder。

3 规格声明与设计要点

3.1 模型定义

在由 `latent_model+tag` 指定的 token 对齐隐空间上，以 ELF 的 rectified flow ($t = 1$ 为干净端) 训练去噪器 G ；推理时 $\hat{x}_0$ 走 VAE-dec 读 token。**BELF** 以块内未知槽同步 t 做半自回归，当前块已知余数钉干净条件；**RELF** 训练逐档独立连续 t ，推理以窗内降序梯子逐步 pop 做滚动半自回归，当前窗已知余数钉干净条件。该分解规定：两族均在连续隐空间上沿该流做观测恢复，并借助已提交前缀的 KV cache 生成至 `max_seq_len`。实现与评测以该分解为准；本文档不预设训练结论。

参数分模型、训练、推理三类，见第 4 节。两族分开训练、分开评测。无并列的次要规格分支。

3.2 设计要点

1. BELF：同一流用于块因果 2L/KV；默认每块 VAE-dec 再 encode (`commit_x0hat=false`)；已知余数钉干净条件；训练每样本连续 $t \sim \text{Ln}$ 算 v-MSE。对照 `true`：提交 $\hat{x}_0$ ，跑满后全文一次 VAE-dec。
2. RELF：将 ELF 流几何用于滚动窗；训练逐档独立 $t \sim \text{Ln}$ ；推理局部时间梯子铺 $L_0, \dots, L_{T-1}$ ，最左档 Euler 到 $1 - \varepsilon$ 后 pop。整窗 F ，BOS 前 / EOS 后截断。已知余数钉干净条件。每步 pop S 个槽。训练未知真槽一律 v-MSE。
3. 训练日程（非第三条机制贡献）：日程档 `full` 下每一族 $\times$ 每一 `latent_tune` 完成主训后再做扩展；日程档 `mid` 仅 Stage1 (10B@128, `eval_step=1000`, `ema_decay=0.999`)。切分见附录 A。预算与 `max_seq_len` 见表。日程档与 `latent_tune=mid` 不是同一键。

4 共性

两族共用加载、映射、 G 、VAE-dec 读出、v-MSE 与训练日程。时间场见第 5 节。读出位置与生成循环见本族章。CFG 见第 6 节；提交与采样器见第 9 节。参数表按模型 / 训练 / 推理分栏；某类无字段则省略该栏。评测长度见附录 A。

4.1 参数三类

超参数划分为模型、训练、推理三类。`latent_model` 与 `tag` 属模型类：二者指定入口自编码器，因而决定入口结构，不再单列「加载」类。

模型。 网络结构。必填 `latent_model` 与 `tag`，无默认，用于调用已有加载器 `load_latent_artifact`。入口 encoder / decoder 在参数表里只记这两项与流维 `latent_dim` (X ，须等于 artifact 输出维)；词表、VAE 层数、s1 系数以加载结果为准，不列表。入口 encoder 的注意力块长以加载结果为准，不随本规格改写。`block_size` 仅 BELF: G 去噪块长，100m 默认 16。加载入口块长须为 1 (逐 token 因果) 或等于本题 BELF W 。可训档 (`full` / `mid`) 另要求入口块长为 1；块因果入口只允许 `frozen`。RELF 无此字段；加载入口块长必须为 1；窗长 `window_size` 与入口无关。

`n_embd` (记 D) 是 G 的隐层宽度，与 X 无关，须整除 `n_head`，全文只声明一次。`max_seq_len` 是位置编码与生成长度上限。出口锁死：无 `exit` 键、无 `linear` 对照； $\hat{x}_0 \in X$ 直接走加载的 VAE-dec 得 logits。主体训练不算出口 CE；VAE-dec 只在推理读出与可训档 $\mathcal{L}_{s1}$ 重建里出现。`self_left_prob` 与 `self_left_thaw_tokens` 进入模型指纹。后者不进消融表。

`sc_cfg` 决定网络是否包含 ScaleEmbedder 与 self-cond 通道，因此进入模型指纹。

训练。 加载之后的优化规则。`latent_tune` 只改变梯度是否反向传播到 latent 本体，不改变加载身份。

<code>latent_tune</code>	含义
<code>frozen</code>	全程冻结。完整 latent 参数仍写入 s2 checkpoint。
<code>full</code>	自 step 0 起更新 latent。
<code>mid</code>	默认。已消费 token 未到 <code>latent_thaw_tokens</code> 时与冻结相同；到达该点后解冻一次，此后与 <code>full</code> 相同。解冻后为新可训参数分配新的优化器状态。

推理。 同一 checkpoint 上的采样规则。提交、采样器与 CFG 尺度见第 9 节与第 6 节。规格上不进入训练身份；现网指纹仍纳入 generate YAML (改 BELF 的 T 默认会换哈希)。BELF 生成使用 `block_generate`，RELF 生成使用 `rolling_generate`。

第二阶段 (s2) 始终训练映射与 G 。冻结档不计算 $\mathcal{L}_{s1}$ 。`full` 与解冻后的 `latent_tune=mid`：只要更新 latent 的任一侧 (encoder、VAE-dec、或两侧)，就必须计算完整的 $\mathcal{L}_{s1}$ (重建 + 后验项 + BERT-mask + ref-KL)。 $\mathcal{L}_{s1}$ 与 $\mathcal{L}$ 分开相加。主体 $\mathcal{L}$ 只有 v-MSE，不含出口 CE。VAE-dec 参数是否更新仍只由 `latent_tune` 决定。可训档的 $\mathcal{L}_{s1}$ 仍经同一 VAE-dec。启动时须具备 VAE-dec。`latent_tune=mid` 解冻前仍不计算 $\mathcal{L}_{s1}$ 。速度误差仍可反向传播到 encoder；2L 左段的 `sg` 只切断 pack 左半，不切断该梯度。

启动校验。 加载结果的 X 须等于配置的 `latent_dim`；入口 encoder 块长以加载结果为准，不随 W 改写。BELF：加载入口 `encoder.block_size` $\in \{1, W\}$ 。RELF 无 `block_size`；加载入口块长必须为 1，且 W 能被 S 整除、 $T = W/S \geq 4$ 。可训档（`latent_tune` 的 `full / mid`）要求入口块长为 1，否则报错拒绝。BELF 推理 `num_sampling_steps` $T \geq 4$ ，否则报错。 G 的宽度等于 D ；出口锁死 VAE-dec，启动必须具备 decoder。各族额外校验见本族章。

4.2 流、去噪器与出口

时间： $t = 1$ 干净、 $t = 0$ 纯噪。流与 v-MSE 在入口输出维 $X = \text{latent_dim}$ （须与 `artifact` 一致）； $D = \text{n_embd}$ 只是 G 隐层。白化留在 X ，茎 $\text{Linear}(X \rightarrow D)$ ，`FinalLayer` 回到 X ：

$$z_t = tx_0 + (1-t)\varepsilon, \quad \hat{v} = \frac{\hat{x}_0 - z_t}{\max(1-t, \varepsilon_t)}, \quad v^* = x_0 - \varepsilon.$$

G 输出干净点估计 $\hat{x}_0 \in \mathbb{R}^X$ ，再转换为速度并计算 v-MSE。分母取 $\max(1-t, \varepsilon_t)$ ，其中 $\varepsilon_t = \text{vel_eps}$ ，以避免 $t \rightarrow 1$ 时除零。干净端默认取后验样本（对照均值）；推理写入 KV 的对象必须与该干净端处于同一空间 X 。

G 是一份网络，不含 ELF `decoder_prob` 双模式。条件通道为 AdaLN-Zero (DiT)，不用 ELF 的 in-context control tokens (`num_time_tokens=0`)。块内 LayerNorm 无仿射；每层调制为 $\text{SiLU} \circ \text{Linear} : D \rightarrow 6D$ ，拆成 attn / MLP 的 shift、scale、gate；残差 $x \leftarrow x + \text{gate} \cdot \text{sub}(\dots)$ 。调制末层权重与偏置零初始化，起步每块为恒等。`FinalLayer` 同样 AdaLN-Zero（调制 $D \rightarrow 2D$ 的 shift / scale），输出线性零初始化。骨干其余不变：RoPE、qk-RMSNorm、SwiGLU。此为默认，不列入设计要点、不列入消融。每一层 AdaLN-Zero 逐列以 (t, w_{sc}, m) 为条件（ m 进入模型指纹；不是序列 token，不改变 $2L / \text{注意力}$ ）：未知列一律 $m = \text{denoise}$ ，`sc_cfg` 为真时再以 w_{sc} 为条件；左段 / 已知 / PAD 不加 m 、不以 w_{sc} 为条件。不再设 $m = \text{decode}$ 。BOS 前、EOS 后的格不在当前窗，同样不加 m 。读 token 发生在推理：默认每块 / 每次 pop 后 VAE-dec；`commit_x0hat=true` 时跑满后再全文一次。主体损失：未知列一律 v-MSE。左段与已知槽不进入 $\mathcal{L}$ 。BELF / RELF 均不引入 m_d/m_c 。注意力与 sc 通道见本族掩码节。

主体损失只有 v-MSE（无出口 CE、无 `lambda_ce / ce_detach_g`）：

$$\mathcal{L} = \lambda_{\text{mse}} \mathcal{L}_{\text{mse}}.$$

逐 token 的 $\|\cdot\|^2$ 对 X 取平均。BELF：每样本抽 $t \sim \text{Ln}$ ，广播到未知槽，右段全部未知有效位算 v-MSE， $m = \text{denoise}$ （可 CFG）。已知槽不进入 $\mathcal{L}$ 。RELF 对切完后仍在窗的未知真槽平均（训练逐档独立 $t \sim \text{Ln}$ ），公式见本族掩码节。 v_{tgt} 是否被 CFG 修正、AdaLN 是否以 w_{sc} 为条件，见第 6 节。可训 latent 时总目标为 $\mathcal{L} + \mathcal{L}_{\text{s1}}$ ：

$$\mathcal{L}_{\text{s1}} = \lambda_{\text{vae}} \text{CE}_{\text{rec}} + \beta \mathcal{R}(q_\phi) + \lambda_{\text{mask}} \mathcal{L}_{\text{mask}} + \lambda_{\text{ref}} \text{KL}(q_\phi \| q_{\phi_{\text{ref}}}).$$

后验项 $\mathcal{R}$ 由 `kl_entropy` 切换：缺键或假（默认 YAML）为 $\text{KL}(q_\phi \| N(0, I))$ ；真为 $\text{KL}(q_\phi \| N(0, I)) + \mathbb{E}[\log q_\phi]$ （对角高斯、不含 μ ，抬 σ ）。开时 `artifact tag` 后缀 `-sigma`。 CE_{rec} 与 BERT-mask 都经 VAE-dec。 $q_{\phi_{\text{ref}}}$ 是 s2 开始时加载器给出的 encoder 冻结副本。`frozen` 时 $\mathcal{L}_{\text{s1}} = 0$ 。

网络默认分为三段：加载器编码、去噪器 G 、推理时的 VAE-dec 读出。 G 一律使用逐位置时间嵌入与 AdaLN-Zero；若本族各位置 t 相同，则广播同一标量。

```

tokens
| load_latent_artifact(latent_model, tag)
| Enc (block-causal) -> z in  $R^{\{S \times X\}}$ 
| optional whiten on X
| G stem: Linear X -> D
v
pack_2l [sg(h_left)|h_t]
+ per-column (t, [w_sc if unknown], [m=denoise if unknown])
-> AdaLN-Zero
| G: n_layer x (AdaLN-Zero -> Attn(RoPE, qk-RMSNorm)
|               -> AdaLN-Zero -> SwiGLU)
| FinalLayer (AdaLN-Zero) D -> X -> x0_hat
v
Exit (locked): x0_hat in X -> VAE-dec (inference readout only)

```

出口叠法。 出口锁死 VAE-dec: 无层数键、无 `exit`、无 `linear`。 $\hat{x}_0$ 已在流空间 X , 直接调用加载的 VAE-dec。VAE-dec 的层数 / 块长以加载结果为准, 不在本规格另建。训练主体不算 CE; 读出只发生在推理。

喂给 VAE-dec 的是流空间码。默认 `commit_x0hat=false`: 每块 / 每次 pop 后 VAE-dec 读词, 再 encode 进 KV (左段与训练默认同构为 encoder 码); 可读 EOS 早停。对照 `true`: 循环内提交 $\hat{x}_0$ (已知余数仍钉 encoder 码), 跑满后再全文一次 VAE-dec; 不按尚未读出的 EOS 早停, NFE 高于早停。外部前缀完整块仍走 encoder。训练窗的句首/句尾切仍按数据里的 BOS/EOS。

2L 与 Cola 块因果结构同构: 已完成段写入 KV 后组内双向、组间单向; 右段可见左段。BELF 的组是本规格 `block_size` W ; RELF 已完成段按加载入口块长 (必须为 1, 即逐 token 因果), 窗内组是档 S 。左段 $t=1$, 不加 m , AdaLN-Zero 不以 w_{sc} 为条件。`sc_cfg` 为真时右段未知槽 (一律 $m = \text{denoise}$) 再以 w_{sc} 为条件。推理时末次流的 $\hat{x}_0$ 走 VAE-dec; $\mathcal{L}_{s1}$ 仍只用它做重建。 G 的注意力可见性按本族掩码节落地。时间梯子与各族如何铺 t , 见第 5 节。

self-left。 推理左段默认是再 encode 的 encoder 码 (`commit_x0hat=false`); 对照 `true` 时是提交的 $\hat{x}_0$ 。训练默认仍是 encoder 干净码。累计 token 未到 `self_left_thaw_tokens` (默认 5B) 时 $p_{\text{left}} = 0$; 到点后以概率 `self_left_prob` (默认 0.25, eval / 生成视为 0) 按样本把左段换成 stop-grad 的末流 $\hat{x}_0$: 先抽 Bernoulli, 仅命中行在 CFG 之前用 GT 左 + 右段钉 $t = 1 - \varepsilon$, $m = \text{denoise}$ 做一次 `no_grad` G (取 x-pred, 不 Euler), 写回 h_{left} , 再跑 teacher / 学生。未命中行不跑该次 G 。0 表示一开始就开 (对照用, 不列消融)。已知余数与 PAD 仍钉 encoder 干净码。这不是当前训练 hop 的 $\hat{x}_0$ 。BELF 与 RELF 共用。

4.3 日程与 checkpoint

Token 预算: 日程档 `full` 下每族 $\times$ 每一 `latent_tune` 各有主训与扩展两份, 不共用 ($B_{\text{main}} / B_{\text{ext}}$ 见表)。日程档 `mid` 仅 Stage1 ($B_{\text{mid}} = 10\text{B}$, 全局序列批 128, `eval_step`=1000, `ema_decay`=0.999), 无扩展。切分长度与档比见附录 A。工程上主训与扩展是两次独立训练 (不同

preprocess / 不同 checkpoint 哈希), 扩展可用更大显存的卡。扩展启动时要求同参主训已正常结束, 并从主训 `checkpoint_latest` 的 EMA 初始化 live 权重 (不恢复优化器)。`latent_tune=mid` 的解冻点落在主训内; 若主训已过解冻点, 扩展立即保持解冻。`checkpoint` 变体为 `fast / mid / full` (路径 `cache/checkpoints/{fast|mid|full}/...`), 与 `latent_tune=mid` 不是同一键。

新 run 自 step 0 调用 `load_latent_artifact`, 扩展 run 再被主训 EMA 覆盖。此后只使用本 run 的 checkpoint 中的 latent 副本。无论是否训练 latent, 该 checkpoint 都必须包含完整 latent 参数。同一 Stage 续训先读取本 run, 再按累计 token 判断是否已超过 `latent_thaw_tokens`。模型类字段进入模型指纹 (包括 `latent_model+tag`、`sc_cfg`、`self_left_prob`); 训练类进入训练指纹 (包括 `latent_tune`)。现网只有一份训练哈希 `build_train_fingerprint`: 整份 model YAML (含 `sampling`) 与 `generate_cfg` 一并纳入; 推理字段因此也会换 run 目录。规格分类上的「推理不进训练指纹」与此现网行为分开: 本次不改全局管线。

4.4 共性参数

下表为 100m 规模默认值。修改默认值须写入对应指纹。 G 与优化器内部见附录。入口 encoder / decoder 只记 `latent_model` 与 `tag`。

名称	符号	释义	默认
模型 (共用)			
<code>latent_model</code>		交给 <code>load_latent_artifact</code> 的家族名。	必填
<code>tag</code>		交给加载器的 tag。kl_entropy 开时后缀 <code>-sigma</code> 。	100m-b32-d1
<code>kl_entropy</code>		s1 后验项: 真则 $\beta(\text{KL} + \mathbb{E}[\log q])$, 假则仅 prior-KL。不进必填键; 缺键或 <code>false</code> 不进指纹。	<code>false</code>
<code>n_embd</code>	D	G 隐层宽。与流空间 X 无关。	768
<code>latent_dim</code>	X	流空间维; 须等于 artifact 输出维。	32
<code>max_seq_len</code>		位置编码与生成长度上限。	4096
<code>self_left_prob</code>	p_{left}	训练时按样本把 2L 左段换成末流 $\text{sg}(\hat{x}_0)$ 的概率; eval / 生成视为 0。未到 <code>self_left_thaw_tokens</code> 时强制为 0。	0.25
<code>self_left_thaw_tokens</code>		累计 token 未到该点时不跑 self-left; 0 表示一开始就开。进指纹, 不进消融。	5B
训练 (共用)			
<code>latent_tune</code>		加载之后是否训练 latent 本体。三档对应三个训练配置哈希。与日程档 <code>mid</code> 不是同一键。	<code>mid</code>
<code>latent_thaw_tokens</code>		仅 <code>latent_tune=mid</code> 的解冻点。	5B
<code>target_tokens</code>	B_{main}	日程档 <code>full</code> 的主训预算 (每族 $\times$ 每一 <code>latent_tune</code>)。	45B
<code>ext_tokens</code>	B_{ext}	日程档 <code>full</code> 的扩展预算。日程档 <code>mid</code> 无此项。	5B
<code>mid_tokens</code>	B_{mid}	日程档 <code>mid</code> 仅 Stage1 的预算。	10B

全局推理参数见第 9 节。CFG 见第 6 节。时间调度参数见第 5 节。

消融。 对照按下列网格执行。`latent_tune` 三档为主网格: 日程档 `full` 下每族 $\times$ 每一档各走主训与扩展预算 (见表), 不计入短训消融。其余训练短训不占用主跑 token 预算, 建议每条

使用扩展预算（切分见附录 A）。无出口 CE，故无 `ce_detach_g`。各表按模型 / 训练 / 推理分栏。全局推理消融见第 9 节。

名称	符号	默认	对照
模型			
<code>self_left_prob</code>	p_{left}	0.25	$\{0, 0.125, 0.25, 0.375, 0.5\}$
训练			
<code>latent_tune</code>		mid	frozen、full（主网格；日程档 full 下每档各走 $B_{\text{main}} + B_{\text{ext}}$ ）
<code>x0_source</code>		z	mu

5 时间调度

两族训练抽连续 $t = \sigma(P_m + P_s Z)$, $Z \sim \mathcal{N}(0, 1)$ （与 ELF 同分布）。推理再把同一分布离散成确定梯子 $\{L_i\}$ 。 T 是推理流步数，不是训练超参：BELF 的 T 为 `num_sampling_steps`（可改）；RELf 的 $T = W/S$ 由窗几何锁死。共性给出 Q 与 $\{L_i\}$ ；BELF / RELF 两小节给出训练如何铺 t 、推理如何走梯子。

5.1 共性

设 $Z \sim \mathcal{N}(0, 1)$ 。 Φ 是它的累积分布函数

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du,$$

Φ^{-1} 是分位函数：对 $p \in (0, 1)$ 有 $\Phi(\Phi^{-1}(p)) = p$ 。实现为 $\Phi^{-1}(p) = \sqrt{2} \operatorname{erfinv}(2p - 1)$ 。 $p \rightarrow 0^+$ 时 $\Phi^{-1}(p) \rightarrow -\infty$ ， $p \rightarrow 1^-$ 时 $\rightarrow +\infty$ ，故端点必须特判。

训练时间取 $t = \sigma(P_m + P_s Z)$ ，即 $\operatorname{logit}(t) \sim \mathcal{N}(P_m, P_s^2)$ ，其中 $\sigma(u) = (1 + e^{-u})^{-1}$ 。该分布的分位函数为

$$Q(p) = \begin{cases} 0 & p = 0, \\ \sigma(P_m + P_s \Phi^{-1}(p)) & 0 < p < 1, \\ 1 - \varepsilon & p = 1. \end{cases}$$

开区间结果再夹到 $[0, 1 - \varepsilon]$ 。 P_m, P_s, ε 见本节参数表。

档位**在概率轴**上等分，不是在 t 上等间隔。 T 是**推理**流步数（亦为 G 次数），不是训练超参：训练不用 T （BELF 按样本抽连续 $t \sim \operatorname{Ln}$ ；RELf 按 W/S 分档抽）。推理须 $T \geq 4$ ，否则报错拒绝。RELf 推理 $T = W/S$ 由窗几何推出。主体无出口 CE，不再另留 decode 跳；概率轴按 T 均分（ $T + 1$ 个点）：

$$L_i = Q\left(\frac{i}{T}\right), \quad i = 0, 1, \dots, T.$$

因而 $L_0 = 0$, $L_T = Q(1) = 1 - \varepsilon$ 。第 i 跳（ $i = 0, \dots, T - 1$ ）在 $t = L_i$ 上跑 G , $\Delta t = L_{i+1} - L_i$ ，末次 Euler 到 $1 - \varepsilon$ 。不再于 $t = 1 - \varepsilon$ 多跑一次 G 。默认 $T = 32$ 、 $P_m = -1.5$ 、 $P_s = 0.8$ （ $\operatorname{logit}(t) \sim \mathcal{N}(-1.5, 0.8^2)$ ，质量偏向更噪端，压低末档 $1/(1 - t)^2$ ）。梯子只用于 generate 离散化：不用每次随机抽 Ln 格，也不用 `linspace(0, 1)`。读出见第 9 节。

名称	符号	释义	默认
模型（共用）			
denoiser_p_mean	P_m	$\text{logit}(t) \sim \mathcal{N}(P_m, P_s^2)$ 的均值。	-1.5
denoiser_p_std	P_s	同上，标准差。	0.8
t_clean_eps	ε	$Q(1) = L_T = 1 - \varepsilon$ ；末次 Euler 终点；self-left 提交前向亦用此点。	0.05

5.2 BELF

`train_t_schedule=independent`。每次前向按样本抽 $t = \sigma(P_m + P_s Z)$ ，将该 t 广播到当前块的未知槽。全部未知槽 $m = \text{denoise}$ ，监督该 t 上流的信噪比（v-MSE； $g = 1$ 时可按 CFG 修正 v_{tgt} ），以 w_{sc} 为条件。已知槽钉 $t = 1$ ，不加 m 、不加噪。切块对齐 $0, W, 2W, \dots$ 。已提交的完整块进入 KV，流仅作用于当前块的未知槽。推理 `block_generate` 共 T 次 G ($T = \text{num_sampling_steps}$ ，默认 32，可改)：跳 $i = 0, \dots, T-1$ 未知槽 $t = L_i$ ，Euler $\Delta t = L_{i+1} - L_i$ （末流从 L_{T-1} 走到 $1 - \varepsilon$ ）。默认随后 VAE-dec 读词再 encode；对照 `commit_x0hat=true` 则提交 $\hat{x}_0$ 、跑满后再读出。已知槽每跳钉 $t = 1$ 并覆写为 encoder 干净码。混合块如何自生成、如何训，见第 7.1 节。

5.3 RELF

`train_t_schedule=block`。不设 `p_preroll` / `p_freeroll` / `p_postroll`，也不按 Cat 抽支。时间场以档为单元：每档 S 槽共享同一流时间。**训练**对每一档独立抽 $t \sim \text{Ln}$ （档内 `repeat_interleave`），不再铺固定梯子。**推理**仍用确定梯子 $L_i = Q(i/T)$ ， $T = W/S$ 锁死，不可改 `num_sampling_steps`。未知档每步只升一档（接到更高的 L_i ，最左档从 L_{T-1} Euler 到 $1 - \varepsilon$ ）。每次训练前向只指定当前窗的一帧 t 场。

先构造**整窗**推理 `freeroll` 场 F ：位置 $k = 0, \dots, W-1$ ，

$$F_k = L_{T-1-\lfloor k/S \rfloor}.$$

即档 $r = 0, \dots, T-1$ 占槽 $[rS, (r+1)S)$ ，值为 L_{T-1-r} 。最左档 $t = L_{T-1}$ （末流起点），右组纯噪 L_0 。窗内不铺 $L_T = 1 - \varepsilon$ 。这把 F 是唯一模板。

截断看 **BOS / EOS 落在虚拟满窗的哪一格**，不是先抽档数再把 F 左右搬去凑满 W 。记 BOS、EOS 的文档下标为 i_{bos} 、 i_{eos} （均含该 token）。PAD 不是边界。窗起点 u 按文档起点 S 格对齐，覆盖 $[u, u+W)$ 。对窗内格 $k = 0, \dots, W-1$ ，文档下标 $j = u + k$ ：

- $j < i_{\text{bos}}$ ：**BOS 之前**，整段丢掉，不在当前窗。
- $j > i_{\text{eos}}$ ：**EOS 之后**，整段丢掉，不在当前窗。
- 否则：真槽。推理 $t_k = F_k$ （沿用满窗 F 在该格上的值）；训练该档独立抽 $t \sim \text{Ln}$ 。

丢掉的位置不赋 $t = 0$ 、不赋末流终点 $1 - \varepsilon$ ，也不把留下的梯子挪到另一头去凑满 W 。真窗可以短于 W 。

两种切法相互独立、可以叠加，不是互斥分区。对虚拟满窗 F ：

- **句首切 (preroll)**： $j < i_{\text{bos}}$ 的格丢掉。BOS 落在窗内格 $k_{\text{bos}} = i_{\text{bos}} - u$ ，其左全部截掉。

- **句尾切 (postroll)**: $j > i_{\text{eos}}$ 的格丢掉。EOS 落在窗内格 $k_{\text{eos}} = i_{\text{eos}} - u$, 其右全部截掉。

两端都不切 ($u \geq i_{\text{bos}}$ 且 $u + W - 1 \leq i_{\text{eos}}$) 则整窗几何为满窗 (句中 / freeroll)。只切左留下 F 的右侧 (更噪档); 只切右留下 F 的左侧 (更净档); 都切留下 F 的中段。损失按切完后的格计算, 见第 8.3 节。训练在留下的未知档上独立抽 t , 不沿用 F_k 。

抽窗须使交集非空。做了句首切则真窗含 BOS; 做了句尾切则真窗含 EOS。禁止为凑档把 BOS / EOS 挪出真槽; 禁止把 PAD 当截断对象。BOS / EOS 不必落在档界上; 所在档被截成短档时, 留下的槽仍共享该档的 t 。

禁止: 将 token 窗对齐铺满为从 BOS 起的 W 、把最噪档搬到窗左、右侧铺 $t = 0$ 「尚未进入」; 禁止把 F 左侧截掉再把剩余滑到窗右。

不对齐前缀的余数走左切爬梯 (与 preroll 同构), 不是钉在满窗 F 左侧一次读出; 句首切不抽 r 。见第 8.1 节。

6 CFG

CFG 含两根相互独立的轴。 w_{sc} 进入右段未知槽 AdaLN (未知一律 $m = \text{denoise}$), 推理为单次前向。 w_{ctx} 在训练时以概率丢弃前缀; 推理默认 $w_{\text{ctx}} = 2$, 另需无前缀支路, 共两次前向 ($w_{\text{ctx}} = 1$ 时仅带前缀一次前向)。推理时 VAE-dec 只读取末次流的 $\hat{x}_0$ 。无「纯 decode 步」: 每跳都可跑 teacher。

6.1 w_{sc} : self-cond CFG

条件对象为上一跳的 $\hat{x}_0$ 。启用时 w_{sc} 进入 AdaLN 的 ScaleEmbedder, 与 t 的 TimestepEmbedder 分开。推理为单次前向。

启动开关。 `sc_cfg` 默认 `true` (主跑打开 ScaleEmbedder 与 teacher), 进入模型指纹, 因其决定网络是否包含 ScaleEmbedder 与 self-cond 通道。为假: 不构建 ScaleEmbedder、无 sc 通道、AdaLN 不以 w_{sc} 为条件 (仍逐列加 m)、 $v_{\text{tgt}} = v_z$ 、不做 teacher 的 Δv 前向; 推理忽略 `w_sc`。消融单独短训关掉 (`false`)。为真时必须具备 sc 通道, 且 `self_cond=true`。

训练采样。 `sc_cfg` 为真时, 每个样本独立采样两项:

1. w_{sc} : 对齐 ELF, 在 logit-normal 上采样后再仿射到给定区间, 而非在该区间上均匀采样。先采样

$$z \sim \mathcal{N}(P_m^{\text{sc}}, (P_s^{\text{sc}})^2), \quad u = \sigma(z),$$

再按 ELF `sample_cfg_scale` 映到区间:

$$a = 1 + w_{\text{min}}^{\text{sc}}, \quad b = 1 + w_{\text{max}}^{\text{sc}}, \quad w_{\text{sc}} = a (b/a)^u - 1.$$

$P_m^{\text{sc}}, P_s^{\text{sc}}$ 见表; $w_{\text{min}}^{\text{sc}}, w_{\text{max}}^{\text{sc}}$ 见附录。该分布既不是 $\text{Unif}[w_{\text{min}}^{\text{sc}}, w_{\text{max}}^{\text{sc}}]$, 也不是对 w_{sc} 本身的 LogUnif 。

2. $g \sim \text{Bern}(\text{sc_guided_prob})$: 是否按 CFG 修正速度目标, 以及是否将 uncond 的 $\hat{x}_0$ 写入 sc 通道。

$g = 0$ 时仍采样 w_{sc} 并写入右段未知槽 AdaLN, 使推理所用的 w_{sc} 落在训练边缘分布内。`sc_cfg` 为假时不采样这两项。

启用时的一次 step。 三次前向使用同一个已采样的 w_{sc} (两个 teacher `no_grad`, 一个学生), w_{sc} 写入右段未知槽 AdaLN:

1. Teacher uncond: self-cond 通道全 0 $\rightarrow \hat{x}_0^u, v_u$ 。仅 $g = 1$ 的行运行; $g = 0$ 跳过, $v_{tgt} = v_z$ 。
2. Teacher cond: 通道 $sg(\hat{x}_0^u) \rightarrow v_c$ 。同样仅 $g = 1$ 。
3. 学生: 整批未知列对 v_{tgt} 计算 v-MSE。 $g = 0$ 时 sc 通道为 0。

$$v_{tgt} = \begin{cases} v_z + (1 - 1/w_{sc})(v_c - v_u) & g = 1, \\ v_z & g = 0. \end{cases}$$

CFG 对 v_{tgt} 的修正施加于右段未知列。 $g = 1$ 时学生的 sc 通道为 $sg(\hat{x}_0^u)$; $g = 0$ 时通道为 0 (未知槽 AdaLN 仍以已采样的 w_{sc} 为条件)。左段与已知槽 AdaLN 不以 w_{sc} 为条件。提交与 `forward_clean` 同左段。Teacher 的 Δv 对目标 stop-grad。

训练实现 (等价, 不进指纹)。 `self-left` 换完左段之后, 对最终左段茎一次并 `prefill_left` (带梯度; 茎后 `sg` 对齐 2L pack 左半)。随后 G_u/G_c /学生只跑右段, 注意力可见性与完整 2L 右块相同。`self-left` 那次 G 仍是完整 2L, 不共用这份 KV。生成循环仍按 hop 维护左 KV, 不走训练这条 `prefill`。不改 v_{tgt} 、sc、AdaLN 语义。

BELF: 未知槽共享同一套 sc。已知槽 sc 为 0。RELF: 即使 $g = 1$, 窗内最右 S 个新噪声槽的 sc 仍为 0 (尚无上一跳估计)。左段与干净槽的 sc 为 0。最左档与其余未知档同样以 w_{sc} 为条件。

推理: 未知槽 sc 为上一步提交的 $\hat{x}_0$ (序列开始或新块/新槽/已知槽为 0); 未知槽 AdaLN 以推理 w_{sc} 为条件。前缀 KV 不随 w_{sc} 重算。

6.2 w_{ctx} : 上下文 CFG

条件对象为 2L 左段 / KV 前缀, 与 w_{sc} 独立, 不进入 AdaLN。

训练采样。 每个样本再独立采样 $d \sim \text{Bern}(p_{\text{drop}}^{\text{ctx}})$ (与 g 、 w_{sc} 均独立)。 $d = 1$ 时丢弃 2L 左段, 仅训练当前块/窗。此为训练期的无条件上下文。

推理默认 $w_{ctx} = 2$, 做上下文外推: 无条件支路为**无前缀、仅运行当前块/窗**。然后

$$v = v_u^{\text{ctx}} + w_{ctx}(v_c^{\text{ctx}} - v_u^{\text{ctx}}).$$

$w_{ctx} = 1$ 时仅运行带前缀的一次前向。消融取值见表。

6.3 CFG 参数

名称	符号	释义	默认
模型			
sc_cfg		是否启用整套 w_{sc} (含 sc 通道)。为假则无通道、不构建 ScaleEmbedder、不以 CFG 修正 v_{tgt} 。进入模型指纹。主跑开；消融关。	true
训练			
self_cond_cfg_p_mean	P_m^{sc}	训练 w_{sc} 的 logit-normal 位置。对齐 ELF 原时间场，不随梯度 P_m 改。	-1.5
self_cond_cfg_p_std	P_s^{sc}	尺度。	0.8
sc_guided_prob	p_g^{sc}	仅 sc_cfg: 本 step 按 CFG 修正速度目标并写入 sc 通道的概率。	0.5
ctx_p_drop	p_{drop}^{ctx}	丢弃 2L 左段的概率。与 g 独立。不进消融。	0.1
推理			
w_sc	w_{sc}	推理尺度。sc_cfg=false 的 ckpt 忽略。YAML / sampling 键名即此；实现仍接受 ELF 别名 self_cond_cfg_scale，但已写 w_sc 时别名不生效。	2.0
w_ctx	w_{ctx}	推理上下文外推；1= 不外推。YAML 键名即此；别名 w_cfg / ctx_cfg_scale 同上。	2.0

训练 w_{sc} 的 logit-normal 参数见表；采样区间 $w_{min}^{sc}, w_{max}^{sc}$ 见附录。推理 w_{ctx} 允许区间 $w_{min}^{ctx}, w_{max}^{ctx}$ 见附录。推理尺度可在同一 checkpoint 上更改，不进入训练指纹。仅 sc_cfg=true 训练得到的 run 才对推理 w_{sc} 做扫描；前缀 KV 不随 w_{sc} 重算。sc_cfg=false 的 run 不对 w_{sc} 扫描。全局提交、采样器与温度见第 9 节。

6.4 CFG 消融

对照按下列网格执行。主跑 sc_cfg=true；关掉 w_{sc} 须单独短训。推理项使用同一 checkpoint。按槽拆损失已确定，见第 10 节，不作为消融项。ctx_p_drop 不进消融。

名称	符号	默认	对照
模型			
sc_cfg		true	false (单独短训关掉整套 w_{sc} 与 sc 通道)
推理			
w_sc	w_{sc}	2	{0.5, 1, 2, 3}; 仅 sc_cfg=true
w_ctx	w_{ctx}	2	{1, 2, 3, 5, 7}

7 BELF

块半自回归。联合分布写成 $p(z_0) = \prod_b p_G(z_0^{(b)} | z_0^{(<b)})$ 。每一块是一条条件 rectified flow: 未知槽共享同一标量 t ；已知余数钉 $t = 1$ 。去噪块长等于本规格 block_size (W): 100m 默认 16。加载入口块长须 $\in \{1, W\}$ ；可训档另要求入口块长为 1。入口 encoder 仍按其加载块长做块因果，不随 W 改写。训练每样本抽连续 $t \sim \text{Ln}$ ，对该 t 全部未知有效位算 v-MSE。对照

$W = 1$ 时推理 T 仍见表，不强制 $T = 1$ 。 W 进模型指纹；BELF 的 T 进 generate YAML。当前块内已知余数如何自生成、如何训，见第 7.1 节。

7.1 Clean

主跑 `cond_mode=clean`。本节规定两件事：**自生成**（推理时已知余数与已提交前缀从哪来）和**训练**（如何抽到同构的混合块）。损失与注意力见第 7.3 节。

格子。 切块对齐 $0, W, 2W, \dots$ 。前缀长 L 时 $r = L \bmod W$ 。完整块 $\lfloor L/W \rfloor$ 进入 KV；当前块起点 $\lfloor L/W \rfloor \cdot W$ 。末块可短只指序列末端不够一整块。 $r = 0$ 时当前块没有已知余数。 $W = 1$ 时 r 恒为 0，clean 不触发、不抽混合块。

自生成。 `block_generate` 给定前缀 token（长 L ）：

1. **已齐的完整块**写入 KV。同一次生成循环里刚写完的块：默认 VAE-dec 读词再 encode (`commit_x0hat=false`)；对照 `true` 则提交 G 的 $\hat{x}_0$ 。若这次调用的前缀是外部文本（提示），完整块走 encoder、`sample=false`。这是左段干净条件，不是当前块内的余数。
2. **当前块已知余数**只在 $r > 0$ 时出现：槽 $[0, r)$ 钉 $t = 1$ ，码是前缀对应位置的 encoder 干净码，不进入损失。这 r 个 token 可以是提示。 $r = 0$ 则整块未知。
3. 未知槽从噪声走 T 次流。每跳之后把已知槽覆写回 encoder 干净码并钉 $t = 1$ ，避免 Euler / SDE 冲掉已知位。块内 T 次流不中途读词。
4. 本块结束后写入 KV（默认 encode 读出词；对照提交 $\hat{x}_0$ ）。此后下一块整块未知：自生成的完整块只出现在左段 KV，不再以块内余数出现。
5. 默认可按 EOS 早停，再 `pad_after_first_eos`。对照 `true` 跑满后再全文一次 VAE-dec，不早停。

训练。 以概率 `clean_block_prob` 把当前块抽成混合块：有效长 W' （末块可短），切点 $r \sim \text{Unif}\{1, \dots, W' - 1\}$ 。槽 $[0, r)$ 为已知 ($t = 1$ 、不进损失)， $[r, W')$ 为未知（走该样本连续 t ）。其余前向整块均为未知。 $W = 1$ 或 $W' \leq 1$ 时不抽混合块。已知槽始终是 encoder 码，不用 $\hat{x}_0$ 冒充余数。右段 unknown Q 不可见同块 PAD K。可训档硬拒入口块长 $\neq 1$ ，不必二次 encode。仅冻结档且入口块长 $= W$ 时，余数再 encode 一份条件句（当前块 $[r, W)$ 写成 PAD），已知覆写与 PAD 干净码用这份；插值靶仍来自整句 encode。左段 KV 训练时默认是 encoder 干净码（教师强制），累计 token 到 `self_left_thaw_tokens` 后以概率 `self_left_prob` 换成末流 $\text{sg}(\hat{x}_0)$ （见第 4.2 节）；推理左段默认是再 encode 的 encoder 码，对照 `commit_x0hat=true` 时是提交的 $\hat{x}_0$ 。

排除项。 不随机挪块界。任意位置填空（左右都有干净上下文）须改 2L 可见性，不在本文档范围。




图 1: BELF clean: 当前块左侧为已知余数, 钉干净、不进损失; 右侧未知槽走块内同一 t 。橙为末流档 (仍是 v-MSE)。

续写见图 2: 前缀对不齐块界时, 先在当前块未知槽上走完 T 次流、提交 $\hat{x}_0$; 此后下一块整块未知。读词只在全文结束。



图 2: BELF clean 续写 ($W = 4$, 前缀 $L = 6$ 故 $r = 2$)。从左到右为相继的 G 帧。在混合块未知槽上走完流后提交 $\hat{x}_0$; 提交后下一块整块未知。绿格为块内已知余数 ($t = 1$, 不进损失)。流跳只画一帧 (未知槽同一 t)。红框为该帧提交的 latent (读词只在全文结束)。

7.2 训练

加载并按 `latent_tune` 编码, 按 W 切块 (主训切分见附录 A), 映射后 2L pack。CFG 采样见第 6 节。切块对齐 $0, W, 2W, \dots$ 。训练要求序列长度被 W 整除, 否则报错拒绝; 混合块余数按满块 W 抽取 $r \sim \text{Unif}\{1, \dots, W-1\}$, 不按短末块有效长 W' 。推理末块可短, 见第 7 节推理。是否混合块、已知槽如何钉干净, 见第 7.1 节。按第 5.2 节指定右段时间并加噪: 未知槽每样本抽连续 $t \sim \text{Ln}$; 已知槽见 Clean 节。

未知槽 $z_t = tx_0 + (1-t)\varepsilon$ 。右段全部未知有效位计算 v-MSE: $m = \text{denoise}$ (可 CFG), 训练 $t \sim \text{Ln}$ 。已知槽不进入 $\mathcal{L}$ 。不引入 m_d/m_c 。注意力与 sc 通道按第 7.3 节排布。左段默认 encoder 干净码; 以概率 `self_left_prob` 换成末流 $\text{sg}(\hat{x}_0)$ (见第 4.2 节)。

接口: `forward(tokens)` 计算一块或一批块的混合损失。配置 `train_t_schedule=independent`。生成使用 `block_generate`。混合块见第 7.1 节。

7.3 掩码排布

一次前向的 pack 是 [左段前缀 | 右段当前块]。切块对齐 $0, W, 2W, \dots$ 。一批块时右段按块拼接，各块独立套用下列规则，禁止跨块右段相互可见。**训练**序列长度须被 W 整除，因而训练右段没有短末块。推理末块可短于 W （序列末端不够一整块）。pad 不计入损失。左段与已知槽不进入 $\mathcal{L}$ 。损失为右段未知有效位平均，见训练节；不引入 m_d/m_c 。

注意力。 见图 3。已完成块写入 KV：块内双向、块间单向（后块可见前块）。当前块内双向，且可见文档位置早于本块起点的已完成内容；已完成块不能看当前块。一批右段时各块独立，禁止跨块互看。 $p_{\text{drop}}^{\text{ctx}}$ 时切断左段。




图 3: BELF 一次前向的注意力。查询看行、键看列。




图 4: BELF: 已完成的前块不算损失。未知槽算速度 MSE（训练一次连续 $t \sim \text{Ln}$ ）。橙为推理末流档（该步 Euler 后提交 $\hat{x}_0$ ），仍是 v-MSE。

self-cond 通道。 未知槽共享同一套 sc。新块起始训练为 0；推理使用上一跳 $\hat{x}_0$ 。左段与已知槽恒为 0。 $p_{\text{drop}}^{\text{ctx}}$ 只改变注意力。已知槽 AdaLN 仅以 $t = 1$ 为条件，不加 m 、不以 w_{sc} 为条件。未知槽以 w_{sc} 为条件。

7.4 推理

block_generate。前缀如何切成「完整块进 KV + 当前块左侧已知余数」、每跳如何覆写已知槽、块结束后如何写入 KV，见第 7.1 节。未知槽共 T 次 G ：跳 $i = 0, \dots, T-1$ 未知槽 $t = L_i$ ，Euler $\Delta t = L_{i+1} - L_i$ （末流从 L_{T-1} 到 $1-\varepsilon$ ）。默认随后 VAE-dec 读词再 encode，可按 EOS 早停；对照 `commit_x0hat=true` 则提交 $\hat{x}_0$ 、跑满后再读出。只要总长未到 `max_seq_len`，后续块整块未知（末块可短）。`sc_cfg` 为真时：未知槽 `sc` 使用上一步 $\hat{x}_0$ ，AdaLN 以推理 w_{sc} 为条件；新块起始与已知槽为 0。采样器见第 9 节。

7.5 BELF 参数

名称	符号	释义	默认
模型			
<code>block_size</code>	W	G 去噪块长。默认见表（100m 为 16）；入口块长独立，须 $\in \{1, W\}$ ；可训档另要求入口块长为 1。	16
训练			
<code>train_t_schedule</code>		训练期时间采样规则。锁死 <code>independent</code> ：每样本连续 $t \sim \text{independent}$ Ln。	<code>independent</code>
<code>cond_mode</code>		当前块内已知余数如何条件化。	<code>clean</code>
<code>clean_block_prob</code>	p_{clean}	训练时当前块抽成混合块的概率。不进消融。	0.05
训练长度		<code>forward</code> 要求序列长度被 W 整除，否则报错。切分档须满足此约束。	须整除

未知有效位算 v-MSE（一律 $m = \text{denoise}$ ，可 CFG）；不引入 m_d/m_c 。注意力见第 7.3 节。未知槽同一标量 t ；已知槽钉 $t = 1$ 。生成使用 **block_generate**。加载入口块长须 $\in \{1, W\}$ 。训练序列长度须被 W 整除。默认 W 见表（100m 为 16）。推理 T 见第 9 节 `num_sampling_steps`。`clean_block_prob` 不进消融。全局提交、采样器与温度见第 9 节；CFG 尺度见第 6 节。

7.6 BELF 消融

对照按下列网格执行。全局推理消融（含 T 与蒸馏少步）见第 9 节。未知槽同一 t 、已知槽钉 $t = 1$ 、未知槽均算 v-MSE 为方法规则，不列入本表。`clean_block_prob` 不进消融。

名称	符号	默认	对照
模型			
<code>block_size</code>	W	16	1（去噪块长对照）

`block_size` 去噪块长对照 $W = 1$ 。 T 与蒸馏少步见第 9 节，不在本表。`clean_block_prob` 不进消融。

8 RELF

滚动半自回归。窗内位置 k 具有局部时间 t_k ：

$$z^k = t_k z_0^k + (1 - t_k) \varepsilon^k.$$

训练每档 S 个槽共享同一连续 $t \sim \text{Ln}$ (档间独立), 而非逐槽独立采样时间。推理每档铺同一梯子 L_i 。加载入口块长必须为 1 (逐 token 因果)。RELF 不声明 `block_size`。窗长为 `window_size` (W), 与入口块长无关。须 S 整除 W 且推理 $T = W/S \geq 4$, 否则启动报错拒绝。 T 由窗几何推出, 不是训练超参。当前窗已知余数如何自生成、如何训, 见第 8.1 节。

生成分为三段。Freeroll 为滚动阶段: 整窗铺 F , 梯子有 T 档, 每档 S 个槽, 最左档 $t = L_{T-1}$ 、右侧纯噪。每步一次 G : 未知档 (含最左) 各升一档 (最左 Euler 到 $1 - \varepsilon$), 把最左该步 pop 这 S 槽 (默认随后 VAE-dec 读词再 encode; 对照提交 $\hat{x}_0$), 右端补入 S 个新噪声, 回到 freeroll。 S 只表示档宽与 pop 个数。Preroll 把同一把 F 铺在虚拟满窗上: **BOS 之前整段截掉**。训练窗另可按数据 EOS 做句尾切。推理默认可读已读出的 EOS 早停; 对照 `true` 跑到目标长。总长上限为 `max_seq_len`。

8.1 Clean

主跑 `cond_mode=clean`。本节写窗内已知余数如何自生成、如何训。窗的 t 场 (BOS 前 / EOS 后截 F) 见第 5.3 节; 损失见第 8.3 节。

格子。 从文档起点按 S 对齐。前缀长 L (含 BOS) 时 $r = L \bmod S$, $g = \lfloor L/S \rfloor \cdot S$ 。完整 pop $[0, g)$ 进入 KV。 $S = 1$ 时 r 恒为 0, 不触发余数爬梯。不从任意 L 另开窗离开 S 格。

自生成。 `rolling_generate`。新码一律从 L_0 爬到 L_{T-1} 再 Euler 到 $1 - \varepsilon$ 才提交 / pop; 余数只钉干净, 不让新槽跳过梯子。块内 T 次流不中途读词; 默认 pop 后 VAE-dec, 对照 `commit_x0hat=true` 则提交 $\hat{x}_0$ 。

- $L = 0$: preroll。虚拟窗 $u < i_{\text{bos}}$, BOS 落在窗内、**其左截掉**; u 每次右移 S , 直到 BOS 落到 $k = 0$ 再提交 $\hat{x}_0$ 并进入 freeroll。clean 不介入。见图 9。
- $L > 0$ 且 $r = 0$ 且**已有** z_{carry} : 跳过 preroll 与爬梯。当前窗整窗未知, $t \leftarrow F$, 进入 freeroll。
- $L > 0$ 且 ($r > 0$ 或**尚无** z_{carry}): **余数爬梯** (与 preroll 同构)。对齐前缀冷启动 $r = 0$ 时 `known` 为空、 $n_{\text{write}} = S$ 。余数是文档 $[g, g + r)$ 。共 T 帧, `hop` $h = 0, \dots, T - 1$:
 - 虚拟下标: 余数起点 $k_0 = W - S(h + 1) = S(T - h - 1)$ 。窗原点 $u = g - k_0$ 。 $k < k_0$ 的格丢掉 (不在当前窗; 已写完整 pop 在 KV)。
 - 槽 $[k_0, k_0 + r)$ 为已知 (encoder 干净码, $t = 1$, 不进损失)。其余真槽未知, 铺各格 F_k (F 不滑)。
 - 每帧一次 G 。 $h < T - 1$: 最左流档仍在 k_0 左侧, 已截掉; 未知档 Euler 升一档, 右端补 S 个 L_0 新噪声; **不 pop**; 已知槽覆写 $t = 1$ 。
 - $h = T - 1$: $k_0 = 0$, 即混合满窗 F 。最左档 $t = L_{T-1}$ 亦 Euler 到 $1 - \varepsilon$; 推理 pop 这 S 槽 (已知 r 来自前缀 encoder, 新写 $S - r$ 默认 VAE-dec 读词再 encode, 对照为 $\hat{x}_0$)。随后 freeroll, 窗内不再带余数。训练该帧未知格算 v-MSE, 见训练节。
- BOS 若落在已知余数里: 钉干净, 不当未知, 也不踢出窗。

- 同一次滚动里刚 pop 的槽：默认 VAE-dec 读词再 encode；对照提交 $\hat{x}_0$ 。外部前缀完整 pop 仍先 encode 再提交。

训练。 先取合法窗起点，再按 BOS 前 / EOS 后截 F （须保住 BOS / EOS，PAD 不当截断对象）。 r 是截断生成：已知为已经写出的真 token；切点必须在 EOS / PAD 之前，且至少留一个未知真槽； r 不得 $\geq S$ 。

- **不做句首切：**以概率 `clean_block_prob` 抽余数爬梯的一帧（不是只抽末帧）。先抽 $h \sim \text{Unif}\{0, \dots, T-1\}$ ，再铺该 hop 的左切： $k_0 = S(T-h-1)$ 。句首切判定为 $\text{bos_cut} = (u+k_0) < i_{\text{bos}}$ （留下的第一格是否仍在 BOS 前），不是 $u < i_{\text{bos}}$ 。记该帧切完后真窗长 N' （从 k_0 起到 EOS / 右端）。令 $r_{\text{hi}} = \min(S-1, N'-1)$ 。若 $r_{\text{hi}} \geq 1$ ，则 $r \sim \text{Unif}\{1, \dots, r_{\text{hi}}\}$ ；已知 $[k_0, k_0+r)$ （encoder 干净码、 $t=1$ ），其余真槽未知（窗几何按该 hop 的左切， F 不滑；未知档独立抽 $t \sim \text{Ln}$ ，不铺 F_k ）。 $h=T-1$ 时 $k_0=0$ ，即混合满窗几何。 $h < T-1$ 时最左流档已切掉，只监督更噪档 MSE。句尾切：EOS 不当已知。 $N'=1$ 或 $S=1$ 则不抽。 $T=W/S$ 只用来数 hop，不是训练超参。
- **做了句首切**（留下的格仍有 $j < i_{\text{bos}}$ ）：不抽 r （那是 preroll，BOS 自己爬梯）。不把切掉的左侧改铺 $t=0$ ，也不在更噪的真窗左端再钉干净。两端都切（含句首切）同此。

不为凑档截掉 BOS / EOS 或把 PAD 当截断对象。已知槽与左段训练时默认都是 encoder 码（教师强制）；累计 token 到 `self_left_thaw_tokens` 后以概率 `self_left_prob` 把左段换成末流 $\text{sg}(\hat{x}_0)$ 。推理左段默认是再 encode 的 encoder 码；对照 `commit_x0hat=true` 时是提交的 $\hat{x}_0$ 。训练句尾切仍按数据 EOS；推理默认可读已读出的 EOS 早停。

排除项。 任意位置填空（左右都有干净上下文）不在本文档范围。禁止把余数钉在满窗 F 左侧、一次 G 就读出（新词须走完 $L_0 \rightarrow L_{T-1}$ 再 Euler 到 $1-\varepsilon$ ）。




图 5: RELF clean 末帧 ($h = T - 1$): 余数已在虚拟 $k = 0$ ，最左流档 Euler 后才提交 $\hat{x}_0$ 。左列句中满窗；右列训练句尾切（数据 EOS 后截掉， F 不滑）。这是爬梯的最后一帧，不是续写全过程。

续写全过程见图 6：这 T 帧就是 $L > 0, r > 0$ 的推理。余数 K 从虚拟窗右端进入、随 hop 左移 S ；其右第一个新槽沿 F 从 L_0 升到 L_{T-1} 再 Euler 到 $1-\varepsilon$ 才提交 $\hat{x}_0$ / pop。训练只抽其中一帧，未知档独立 $t \sim \text{Ln}$ 。不画随后的 freeroll。




图 6: RELF clean 推理续写 ($W = 8, S = 2, r = 1$)。虚拟满窗左切: 绿格 K 第一帧在 $k=6$ (靠右), 之后每次左移 S 。红框为即将提交的 latent: 末流档 L_{T-1} Euler 后才提交。末帧 K 在 $k=0$, 即混合窗 F , 对应图 5。不画第一次 pop 之后的 freeroll。读词只在全文结束。

8.2 训练

加载并按 `latent_tune` 编码, 映射后 2L pack。CFG 采样见第 6 节 (guided 时最右 S 槽 sc 仍为 0)。启动时若加载入口块长 $\neq 1$, 或 S 不能整除 W , 或推理 $T = W/S < 4$, 则报错拒绝。窗几何: 先取合法窗起点, 再按 BOS 前 / EOS 后截断 (切法与推理 F 相同)。未知档的 t 按第 5.3 节独立抽 L_n , 不铺 F_k 。是否抽余数爬梯的一帧 (未做句首切), 见第 8.1 节。

各槽按所赋 t_k 独立加噪; 已知槽不加噪。损失与注意力按第 8.3 节排布。未知真槽一律 v-MSE。

接口: `forward(tokens)` 按当前窗相对序列起止截断铺 t 场, 再计算混合损失。配置为 `train_t_schedule=block`。生成使用 `rolling_generate`。混合窗见第 8.1 节。

8.3 掩码排布

一次前向的 pack 是 [左段前缀 | 右段当前窗]。窗长 W , 从 0 对齐。一批窗时右段按窗拼接, 各窗独立套用下列规则, 禁止跨窗右段相互可见。pad 位不进损失, 留在 pack 里。左段与已知槽不进入 $\mathcal{L}$ 。须 S 整除 W (推理 $T = W/S$)。

注意力。 见图 7。与 BELF 同形的是「组内双向、组间单向」: 已完成前段的组是加载入口块长 (必须为 1, 即逐 token 因果); 当前窗的组是档 S (同一档双向, 右档可见左档, 左档不可见右档)。窗可见文档位置早于本窗起点的已完成前段; 前段不能看窗。一批右段时各窗独立, 禁止跨窗互看。 $p_{\text{drop}}^{\text{ctx}}$ 时切断左段。




图 7: RELF 一次前向的注意力。查询看行、键看列。

损失。 仅施加于右段。先按第 5.3 节把窗几何切完 (与推理 F 同一套切), 再对**仍在窗的未知真槽**算 v-MSE (各未知档独立 $t \sim \text{Ln}$)。不是按句中 / 句首 / 句尾查表; 两种切法叠在同一窗上仍用同一式。已知槽、PAD、以及 BOS 前 / EOS 后丢掉的格不进 $\mathcal{L}$ 。未知真槽一律 $m = \text{denoise}$ (可 CFG):

$$\mathcal{L} = \lambda_{\text{mse}} \frac{\sum_{k \in \mathcal{U}} \|\hat{v}_k - v_{\text{tgt},k}\|^2}{|\mathcal{U}|},$$

其中 $\mathcal{U}$ 为切完后的未知真槽。 $|\mathcal{U}| = 0$ 时该项为 0。余数爬梯: $h < T - 1$ 时最左流档在 k_0 左侧、已切掉, 只更噪档 MSE; 末帧 $k_0 = 0$ 时已知槽仍为 0, 最左未知格也算 v-MSE。丢掉的格不加 m 。




图 8: RELF 画的是虚拟满窗推理 F ($W = 8$, 每档 2 槽)。黄净、黑噪。橙 = 最左流档 $t = L_{T-1}$ (该步 Euler 到 $1 - \varepsilon$ 后提交 $\hat{x}_0$); 蓝 = 更噪流档。灰格是 BOS 之前或 (训练) EOS 之后, 不在窗、不赋 $t = 0$ 。前三列是只切一侧或都不切; 右列两端都切。推理损失几何按切完后的 F_k 按格; 训练在留下的档上独立抽 t 。

self-cond 通道。 右段已有上一跳估计的未知槽写 $\text{sg}(\hat{x}_0^u)$ (guided 时)。最右新进的 S 个噪声槽 sc 恒为 0。最左档与其余未知档同样以 w_{sc} 为条件。左段 / 已知槽 / 干净槽为 0。 $p_{\text{drop}}^{\text{ctx}}$ 只改注意力。已知槽 AdaLN 仅以 $t = 1$ 为条件，不加 m 、不以 w_{sc} 为条件。

8.4 推理

rolling_generate。 前缀如何切成「完整 pop 进 KV + 余数爬梯」、 $L = 0$ 是否 preroll、 $r > 0$ 时 T 帧后才第一次 pop，见第 8.1 节。推理滚动跑满目标长，不按尚未读出的 EOS 改 postroll；训练窗句尾切仍按数据 EOS。首词如何落到最左流档再被提交，见图 9。




图 9: RELF 推理提交 ($W = 8$, 每档 $S = 2$)。上行句首切: 窗起点 u 每次右移 S , BOS 在虚拟满窗上左移; 前三帧最左流档仍在 BOS 之前 (已截掉), 无提交; 末帧 BOS 落到 $k = 0$, 该档 Euler 后 pop。下行训练句尾切: 数据 EOS 之后丢掉、不再右补噪声。推理默认可读已读出的 EOS 早停; 对照 **true** 跑满后再全文 VAE-dec。灰格不在窗, 不赋 $t = 0$ 。

sc_cfg 为真时: 未知槽 sc 使用上一步提交的 $\hat{x}_0$, AdaLN 以推理 w_{sc} 为条件; 开局、新进噪声槽与已知槽为 0。采样器见第 9 节。

8.5 RELF 参数

名称	符号	释义	默认
模型			
window_size	W	滚动窗长。须能被 S 整除；推理 $T = W/S \geq 4$ 。	64
step_size	S	每步从窗左端 pop 的槽数，亦为档宽。推理 $T = W/S$ 锁死。	2
训练			
train_t_schedule		训练期时间采样规则。锁死 block：逐档独立连续 $t \sim \text{Ln}$ 。	block
cond_mode		当前窗内已知余数如何条件化。	clean
clean_block_prob	p_{clean}	未做句首切时抽余数爬梯一帧的概率（含 hop h 与 r ；切点在 EOS 前）。不进消融。	0.05

生成使用 `rolling_generate`。推理窗的 t 场由句首切 / 句尾切对整窗 F 给出，两切可叠加，不另设分支概率。余数爬梯见第 8.1 节。训练未知真槽一律 v-MSE（逐档独立 $t \sim \text{Ln}$ ），不进参数、不进消融。`clean_block_prob` 不进消融。消融见下表。全局提交、采样器与温度见第 9 节；CFG 尺度见第 6 节。

8.6 RELF 消融

对照按下列网格执行。改 W 时须保持 S 整除 W （推理 $T = W/S \geq 4$ ）。全局推理消融（含 BELF 的 T 与蒸馏少步）见第 9 节。未知真槽一律 v-MSE，不进消融。`clean_block_prob` 不进消融。

名称	符号	默认	对照
模型			
window_size	W	64	改 W 时同步改 S （须 S 整除 W ；推理 $T = W/S$ ）
step_size	S	2	1（须 S 整除 W ）

改 W 时须 S 整除 W 。蒸馏少步与 BELF 的 T 见第 9 节；RELF 不可改推理 T 。主跑不蒸馏。`clean_block_prob` 不进消融。

9 推理

本节给出两族共用的推理项。规格上这些字段可在同一 checkpoint 上更改，不进入训练身份。现网 `build_train_fingerprint` 仍纳入 generate YAML，故改 BELF 的 T 默认会换哈希；不改全局管线。BELF 生成使用 `block_generate`，RELF 生成使用 `rolling_generate`。CFG 的推理尺度见第 6 节。

T 是推理参数，训练不用 T ：BELF 每样本抽连续 $t \sim \text{Ln}$ ；RELF 按 W/S 分档抽连续 t 。BELF 的 T 须写在 generate YAML 的 `num_sampling_steps`（默认 32，可改，缺键报错）；RELF 推理 $T = W/S$ 锁死，generate YAML 禁止改。

默认 `commit_x0hat=false`：每块 / 每次 pop 后 VAE-dec 读词，再 encode 进 KV；可读 EOS 早停。对照 `true`：将 G 的 $\hat{x}_0$ （流空间 X ）写入 KV，跑满后再全文一次 VAE-dec，不按尚未读出的 EOS 早停。外部前缀完整块仍走 encoder、`sample=false`。训练时左段默认是 encoder

的干净码，累计 token 到 `self_left_thaw_tokens` 后以概率 `self_left_prob` 换成末流 $\text{sg}(\hat{x}_0)$ 。VAE-dec 无状态，不维护 KV。写入 KV 时左段 $t = 1$ ，AdaLN 不以 w_{sc} 为条件，sc 通道为 0。

采样默认 `sampling_method=sde` (γ 见表)，对照 `ode.sde` 时 churn 关在最后一次流 (BELF 跳 $T - 1$; RELF 升档侧，含最左末流)。`sc_cfg` 为真时，未知槽 AdaLN 以推理 w_{sc} 为条件 (仅开训 checkpoint 可扫描)。前缀 KV 不随 w_{sc} 重算。

9.1 推理参数 (全局)

名称	符号	释义	默认
推理			
<code>commit_x0hat</code>		关 = VAE-dec 读词再 encode; 开 = 提交 $\hat{x}_0$, 全文一次 VAE-dec。	<code>false</code>
<code>num_sampling_steps</code>	T	BELF 推理流步数。须 $T \geq 4$ 。RELF 禁止改 ($T = W/S$)。	32
<code>sampling_method</code>		<code>sde</code> 或 <code>ode</code> 。	<code>sde</code>
<code>sde_gamma</code>	γ	仅 <code>sde</code> 的噪声系数。	1.5
<code>temperature</code>		出口温度; ≤ 0 为 <code>argmax</code> 。	0.0

9.2 推理消融 (全局, 不重训)

对照按下列网格执行。同一 checkpoint。 $w_{\text{sc}} / w_{\text{ctx}}$ 扫描见第 6 节。评测长度见附录 A。`sde_gamma` 取值对齐 ELF 已报告的工作点: 论文默认 1.0; 32 步设定 1.5 (本文档默认); 8/16 步设定 2.0。 $\gamma = 0$ 时 SDE 退化为 ODE, 与 `sampling_method=ode` 等价, 故消融不另列 $\gamma = 0$ 。少步蒸馏的评测轴就是下行 BELF 的 T (配方待定, 见第 10 节); 主跑不蒸馏。从零训少步不再单列。

名称	符号	默认	对照
推理			
<code>commit_x0hat</code>		<code>false</code>	<code>true</code> (提交 $\hat{x}_0$, 全文一次 VAE-dec)
<code>sampling_method</code>		<code>sde</code>	<code>ode</code>
<code>sde_gamma</code>	γ	1.5	{1.0, 1.5, 2.0}; 仅 <code>sde</code>
<code>num_sampling_steps</code>	T	32	BELF {8, 16, 64} (同一 ckpt; {16, 8} 亦作蒸馏少步对照)。RELF 锁死 $T = W/S$, 不进本行
<code>distill_time_step</code>	T'	(关)	配方待定; 评测轴即上行 BELF 少步 T , 不另训、不改 W

10 设计选择与未决项

前面各章给出已确定的做法。本章记录已闭合的设计选择, 以及仍未确定的项。其中「出口 CE」与「左条件暴露偏差」两项以问题 / 解决方案对陈述; 其余小节仍为直接结论。

10.1 已确定: w_{sc} 进入哪一段 AdaLN

左段是 $t = 1$ 的干净前缀。若 AdaLN 亦以推理 w_{sc} 为条件, 前缀 KV 会随 w_{sc} 变化, 与训练中「左段不以 w_{sc} 为条件」不一致。规格如下: 仅右段未知槽以 $(t, w_{\text{sc}}, m = \text{denoise})$ 为条

件。不再设 $m = \text{decode}$ 。提交、左段与已知槽均不以 w_{sc} 为条件、不加 m 。 $g = 0$ 时 sc 仍为 0，但未知槽 AdaLN 仍以已采样的 w_{sc} 为条件。扫描 w_{sc} 时不重算前缀 KV。见第 6 节、第 9 节。

10.2 已确定：BELF / RELF 用 clean 处理已知余数

主跑 `cond_mode=clean`。自生成与训练抽样见第 7.1 节、第 8.1 节，此处不复述。RELF：推理时新槽从 L_0 爬到 L_{T-1} 再 Euler 到 $1 - \varepsilon$ 才提交 / pop；训练未做句首切时只抽余数爬梯的一帧 ($h \sim \text{Unif}\{0, \dots, T-1\}$, $T = W/S$)，未知档独立 $t \sim \text{Ln}$ 。句首切不抽 r 。禁止钉满窗 F 左侧一次提交。任意位置填空不在本文档范围。已确定。

10.3 已确定：出口 CE / decode hop 拉坏流训练

问题。旧规格在 $T-1$ 次流之外另留一档 decode hop：在 $t = 1 - \varepsilon$ 再跑 G ，并对出口打 token CE (`lambda_ce / ce_detach_g / exit`)。CE 与 v-MSE 目标不一致，容易把流场与读出拉向不同方向；评测若用出口 CE 充当 PPL，还会与推理真正走的 TriFluency / Gen.PPL 脱节。梯子按 $Q(i/(T-1))$ 均分时，分母与「多一档 CE」绑在一起，去掉 CE 后若不改梯子会少一档流。

解决方案。主体 $\mathcal{L}$ 只保留 v-MSE (无 `lambda_ce / ce_detach_g / exit / linear`)。出口锁死为 $\hat{x}_0 \in X$ 再走加载的 VAE-dec：训练主体不算 CE；VAE-dec 只在推理读出与可训档 $\mathcal{L}_{s1}$ 重建里出现。 G 仍一份 (禁止 ELF `decoder_prob` 双模式)。梯子与 hop 对齐：

- T 是推理流步数： $L_i = Q(i/T)$, $i = 0, \dots, T$ ($T+1$ 个点)。不再另留一档 CE / decode hop。训练抽连续 $t \sim \text{Ln}$ 。
- BELF：未知槽一律 v-MSE (可 CFG)；推理默认每块 VAE-dec 读词再 encode，对照提交 $\hat{x}_0$ 后全文一次读出。
- RELF：仍在窗的未知真槽一律 v-MSE (可 CFG)。训练逐档独立 t ；推理最左档 $t = L_{T-1}$ ，该步 Euler 到 $1 - \varepsilon$ 后 pop。训练两种切法可叠加，损失按格、不按三行表；推理默认可读已读出的 EOS 早停。
- AdaLN-Zero 逐列 ($t, w_{\text{sc}}, m = \text{denoise}$)。 m 仅未知真槽；不再设 $m = \text{decode}$ 。BOS 前 / EOS 后不在窗，与满窗右侧 $L_0 = 0$ 的 denoise 真槽不是一回事。
- 主指标沿用仓库 TriFluency / Gen.PPL，不再用出口 CE 充当 eval PPL。

训练插值 z 与推理 Euler z 的轨迹缺口仍在；左条件暴露偏差见下一对。已确定。

10.4 已确定：左条件暴露偏差 (self-left)

问题。链式法则写的是 $p_G(z^{(b)} | z^{(<b)})$ 。推理左段在 `commit_x0hat=true` 时是提交的 $\hat{x}_0$ ；默认 `false` 时是再 encode 的 encoder 码。训练若始终喂 encoder 干净码 (教师强制)，则右段去噪习惯「完美前缀」，一到推理左边带自生成误差就崩。这是左条件上的暴露偏差。用当前训练 hop (随机 t) 的 $\hat{x}_0$ 冒充左段也不行：离提交码太远。块内已知余数与 PAD 另有钉干净规则，不应拿 $\hat{x}_0$ 冒充。

解决方案。累计 token 未到 `self_left_thaw_tokens` (默认 5B, 进指纹、不进消融) 时不跑 self-left。到点后以概率 `self_left_prob` (默认 0.25, eval / 生成视为 0) 做 self-left scheduled sampling: 先抽 Bernoulli, 仅命中行在 CFG 之前用 GT 左 + 右段钉 $t = 1 - \varepsilon$, $m = \text{denoise}$ 做一次 `no_grad G` (取 x-pred, 不 Euler), 把 h_{left} 换成 **stop-grad 的末流** $\hat{x}_0$, 再跑 teacher / 学生。未命中行不跑该次 G 。已知余数与 PAD 仍钉 encoder 干净码。BELF 与 RELF 共用。消融 {0, 0.125, 0.25, 0.375, 0.5} (解冻点不当对照轴)。它不消除「插值 z vs Euler z 」那条缺口, 只缓解左条件分布差。机制见第 4.2 节。已确定。

10.5 已确定：日程档 mid

checkpoint 变体 `fast / mid / full` 与 `latent_tune=mid` (5B 解冻) 不是同一键。日程档 mid 仅 Stage1: 全局序列批 128、主预算 10B、`eval_step=1000`、`ema_decay=0.999`, 用于中档验证, 无 Stage2。路径 `cache/checkpoints/mid/...`。已确定。

10.6 未决：少步蒸馏

蒸馏的评测轴已放进第 9 节: BELF 在同一 checkpoint 上改 `num_sampling_steps` (默认 $T = 32$, 少步对照 {16, 8})。RELF 推理 $T = W/S$ 不可改, 少步须改 W 或 S (模型身份, 不在推理表)。主跑不蒸馏。蒸馏配方尚未确定: 是否冻结已训教师、学生改哪些参数、损失如何书写, 两族同一未决项。从零训少步不再单列 (训练不用 T)。

A 长度日程

切分仅用于构造训练样本。模型只声明 `max_seq_len=4096`。

- 日程档 `full / mid` 的 Stage1 对齐长度 512, 全部样本为该长度。`full` 全局批 512; `mid` 全局批 128、预算 10B、`eval_step=1000`, 无 Stage2。
- 日程档 `full` 的扩展对齐长度 2048; 5B 按档 token 比 1:2:3:4 分成 0.5+1.0+1.5+2.0 B, 档 {256, 512, 1024, 2048}。
- 训练切分止于 2048。2048 < $S \leq 4096$ 仅出现于推理外推。eval 主报 2048, 4096 作为外推。主指标沿用仓库 TriFluency / Gen.PPL, 不再用出口 CE 充当 eval PPL。
- BELF 训练另要求每条样本长度被 W 整除 (100m 默认 $W = 16$; 上列档均满足)。不整除则 `forward` 报错。RELF 无此整除约束。

B 共性参数附表

下列为共性章未列入主表的字段, 仍按模型 / 训练 / 推理分栏。CFG 主表见第 6 节, 全局推理主表见第 9 节。修改这些字段仍须写入对应指纹 (推理类除外), 但本文档不以它们为对照轴。入口 encoder / decoder 只记 `latent_model` 与 `tag`; 隐维、词表、VAE 容量、s1 系数以加载结果为准, 不列入本表。出口锁死 VAE-dec, 无层数键、无 `linear`。表中 100m 数字供该规模实现对齐, 并非另一套规范。BELF 的 `block_size`、RELF 的窗字段在本族章, 不在本表。

名称	符号	释义	默认
模型			
proj_bias		映射是否带偏置。	true
proj_norm		映射后是否 RMSNorm。	rmsnorm
whiten		映射前逐维仿射标准化。	true
whiten_on		白化统计对象。	mu
n_layer		AdaLN-Zero Transformer 层数。	12
n_head		头数。须整除 n_embd。	12
mlp_ratio		SwiGLU 扩展比。	4.0
dropout		注意力 / FFN dropout。	0.0
qk_norm		Q/K 每头 RMSNorm。	true
attn_backend		训练注意力: flex (默认) 或 sdpa。CFG 右段 Flex 为 $Q = N$ 、 $KV = 2N$ (RELF 右长为窗)。生成仍 SDPA。	flex
rope_theta	θ	RoPE 基频。	10000
t_freq_dim		正弦时间嵌入频率维。	256
ada_ln		主跑 AdaLN-Zero (无仿射 LN、残差 gate、调制末层与 FinalLayer 输出线性零初始化)。逐列 (t, w_{sc}, m) ; 未知一律 $m = \text{denoise}$, sc_cfg 为真时再以 w_{sc} 为条件。不再设 $m = \text{decode}$ 。左段与已知槽 $t = 1$ 、不加 m 、不以 w_{sc} 为条件。不用 ELF in-context。不进消融。	true
num_time_tokens		整句时间前缀个数。0= 条件只走 AdaLN-Zero。	0
right_attn		2L 右段内部注意力。	bidirectional
self_cond_mode		self-cond 通道接入方式。	concat ($2D \rightarrow D$)
num_self_cond_cfg_tokens		CFG prefix 个数。本规格为 0。	0
noise_sigma	σ	加噪标准差。	1.0
训练			
self_cond_cfg_min	$w_{\min}^{\text{sc}}$	训练 w_{sc} 区间下界。	0.5
self_cond_cfg_max	$w_{\max}^{\text{sc}}$	训练 w_{sc} 区间上界。	5.0
vel_eps	ε_t	速度分母 $\max(1 - t, \varepsilon_t)$ 的下界。	10^{-3}
lambda_mse	λ_{mse}	v-MSE 系数。无 lambda_ce。	1.0
ctx_source		2L 左段用 z 还是 μ 。	z
x0_source		流的干净端 / v-MSE 靶。	z
optimizer.dtype		训练精度。与 ELF 配方相同。	bf16
learning_rate		AdamW 学习率。与 ELF 配方相同。	0.002
muon_learning_rate		Muon 学习率。与 ELF 配方相同。	0.002
weight_decay		weight decay。	0
muon_weight_decay		Muon weight decay。	0
beta1	β_1	AdamW β_1 。	0.9
beta2	β_2	AdamW β_2 。	0.95

名称	符号	释义	默认
<code>grad_clip</code>		全局梯度裁剪。	1.0
<code>muon_momentum</code>		Muon momentum。	0.95
<code>muon_ns_steps</code>		Muon Newton-Schulz 步数。	5
<code>use_muon</code>		隐藏层 Linear 用 Muon。	<code>true</code>
<code>ema_decay</code>		EMA; 0 关闭。日程档 <code>full/fast</code> 为 0.9999; 日程档 <code>mid</code> 为 0.999。	0.9999 (<code>full</code>)
<code>warmup_ratio</code>		预热占 <code>max_steps</code> 的比例。	0.005
<code>min_lr_ratio</code>		最小学习率相对峰值; 1=constant (BELF/RELF 脚本 <code>--set</code>)。	1.0
<code>global_batch_size</code>		全局批。日程档 <code>full</code> 的 <code>s1</code> 为 512; <code>s2</code> 用 curriculum <code>global_seq_batch=128</code> 。日程档 <code>mid</code> 的 <code>s1</code> 为 128。	512 (<code>full s1</code>)
<code>eval_step</code>		评测间隔 (优化器步)。日程档 <code>full</code> 为 500; 日程档 <code>mid</code> 为 1000 (全局批更小)。	500 (<code>full</code>)
推理			
<code>ctx_cfg_min</code>	$w_{\min}^{\text{ctx}}$	推理 w_{ctx} 下界。	1
<code>ctx_cfg_max</code>	$w_{\max}^{\text{ctx}}$	推理 w_{ctx} 上界。	7

References

- [1] ELF Authors. *ELF: Embedded Language Flows*. 2026. arXiv: [2605.10938 \[cs.CL\]](#).
- [2] ByteDance Seed. *Continuous Latent Diffusion Language Model*. 2026. arXiv: [2605.06548 \[cs.CL\]](#).
- [3] AURORA-LM Authors. *AURORA-LM: Autoencoding Unified Representation for Continuous-Latent Diffusion Language Modeling*. 2026. arXiv: [2608.02602 \[cs.CL\]](#).
- [4] CoDAR Authors. *CoDAR: Continuous Diffusion Language Models are More Powerful Than You Think*. 2026. arXiv: [2603.02547 \[cs.CL\]](#).
- [5] Marianne Arriola, Aaron Gokaslan, Tess Piriyakulkij, et al. “Block Diffusion: Interpolating Between Autoregressive and Diffusion Language Models”. In: *International Conference on Learning Representations*. 2025. arXiv: [2503.09573 \[cs.CL\]](#).
- [6] David Ruhe et al. “Rolling Diffusion Models”. In: *International Conference on Machine Learning*. 2024. arXiv: [2402.09470 \[cs.CV\]](#).